


# Einführung in Neuronale Netze

## Backpropagation Learning


### Lernregel

Es stellt sich die Frage, welches Verfahren den Gewichtsvektor  $\vec{w}$  derartig verändert, daß  $(\vec{w}, F(\vec{w}))$  in ein möglichst **globales Minimum** bewegt wird, **ohne** die gesamte Fehleroberfläche zu kennen.

Hierzu soll nochmals der zweidimensionalen Fall betrachtet werden. Es wird ein  $\vec{w}$  auf der W-Achse gesucht, für das  $F(\vec{w})$  minimal wird.



Das **Backpropagation-Verfahren** beruht auf einem **Gradientenabstiegsverfahren**. Das Verfahren startet mit einem zufällig gewählten Gewicht  $w_1$ . In diesem Punkt wird der **Gradient** bestimmt und um eine vorgegebene Länge, die **Lernrate**, herabgestiegen. Die so erhaltene Gewichtsveränderung liefert den Gewichtsvektor  $w_2$ , in dem wiederum der Gradient bestimmt wird. Das Verfahren wiederholt sich, bis das lokale Minimum erreicht ist.



Durch Betätigen von [vorheriger Schritt](#) und [nächster Schritt](#) wird der Gradientenabstieg für **eindimensionale** Gewichte schrittweise visualisiert. Das Verfahren startet mit der Bestimmung der Tangente in  $w_1$ . Diese wird der **Lernrate** entsprechend weit herabgestiegen und somit die Gewichtsveränderung ermittelt. Zu dem so erhaltenen Gewichtsvektor  $w_2$  wird der zugehörige Fehler bestimmt. Liegt der Fehler oberhalb der zuvor definierten **Güteschwelle**, wird in  $w_2$  die Tangente bestimmt und das Verfahren wiederholt sich, bis der Punkt  $w_{min}$  erreicht wird.

Es muß somit nicht die gesamte Fehleroberfläche bekannt sein, um das Minimum der Fehleroberfläche bestimmen zu können. In diesem Beispiel wird das **Minimum** durch Kenntnis von lediglich **fünf Punkten** der Fehleroberfläche bestimmt.



## Der Gradient

$Q$  bezeichnet die Anzahl der Gewichte im Netz.

Daher sind die Vektoren  $\vec{w}$  wie auch der Gradient  $q$ -dimensional.

Damit lautet die allgemeine Form für die Richtung des Anstiegs:

$$\nabla_{\vec{w}} F(\vec{w}) := \left( \frac{\partial F(\vec{w})}{\partial w_1}, \dots, \frac{\partial F(\vec{w})}{\partial w_q} \right)^T.$$

Backpropagation ist ein Gradienten**abstiegs**-Verfahren. Durch Verschieben von  $\vec{w}$  in Richtung  $-\nabla_{\vec{w}} F(\vec{w})$  kann also ein Minimum der Fehlerfunktion bestimmt werden. Ob dieses Minimum lokal oder absolut ist und welche Probleme aus diesem Unterschied entstehen, wird im Kapitel [Lokale Minima](#) erläutert.

Um den Gradienten zu bestimmen, bietet sich eine Berechnung der einzelnen Komponenten an. Allerdings stellt sich die Frage nach der Existenz dieses Vektors. Die Antwort liefert ein Satz, der von **Hecht-Nielsen** mit Hilfe von statistischen Methoden bewiesen wurde :

**Satz:**

Sei  $F_k(\vec{x}_k, \vec{w}) = |f(\vec{x}_k) - o_{Netz}(\vec{x}_k, \vec{w})|^2$   
 und  $F(\vec{w}) := \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N F_k(\vec{x}_k, \vec{w})$  .

Dann ist  $F$  differenzierbar in  $\vec{w}$  und es gilt :

$$\nabla_{\vec{w}} F(\vec{w}) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \nabla_{\vec{w}} F_k(\vec{x}_k, \vec{w}) .$$

Als abkürzende Schreibweise wird im weiteren verwendet:  $\nabla_{\vec{w}} F(\vec{w}) = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N \nabla_{\vec{w}} F_k(\vec{w})$  .



[Zurück zum letzten Kapitel](#)



[Zum nächsten Kapitel](#)